

## Расчетное задание 1

**Идентификация сообщений, передаваемых по зашумленному каналу связи.**

### *Дано*

По каналу связи передаются буквы  $[x_1; x_2; \dots; x_n]$  в двоичном коде. Последовательность переданных букв образует сообщение. Канал симметричный, вероятность искажения каждого отдельного символа (бита) равна  $q$ . В результате однократной передачи сообщения  $X = [x^{(1)}, x^{(2)}, \dots, x^{(k)}]$  на приемной стороне принято сообщение  $Y_1 = [y_1^{(1)} y_1^{(2)} \dots y_1^{(k)}]$ . В результате повторной передачи того же слова на приемной стороне принято слово  $Y_2 = [y_2^{(1)} y_2^{(2)} \dots y_2^{(k)}]$ . В результате последней ( $m$ -й) передачи того же слова на приемной стороне принято слово  $Y_m = [y_m^{(1)} y_m^{(2)} \dots y_m^{(k)}]$ .

### *Варианты*

Передаваемые буквы (алфавит) и их код приведен в табл.1 приложения. Для каждого студента есть свой вариант в виде текстового файла, названного по фамилии и имени студента. В файле задается число букв в сообщении, разрядность кода (количество бит, используемых при передаче одной буквы), шум (вероятность искажения  $q$ ), число посылок  $m$  и набор из  $m$  посылок (принятых сообщений  $Y^{(i)}$ ).

## **Задание**

### **Часть 1. Последовательная передача одинаковых сообщений**

#### **1.1. Определение переданного сообщения**

- вычислите априорное распределение вероятностей исходных букв алфавита  $p(x_i)$ , рассмотрите два случая (все дальнейшие расчеты в п. 1.1 и 1.2 необходимо будет проделать для этих двух вариантов):
  - все символы равновероятны;
  - вероятности букв задаются исходя из известной информации о частоте букв в русском алфавите (таблица 2);
- вычислите апостериорное распределение вероятностей после 1-й, 2-й и  $m$ -й передач для каждой  $s$  буквы сообщения -  $P(x_i / y_1^{(s)})$ ,  $P(x_i / y_1^{(s)} y_2^{(s)})$ ,  $P(x_i / y_1^{(s)} y_2^{(s)} y_3^{(s)})$ , ...,  $P(x_i / y_1^{(s)} y_2^{(s)} \dots y_m^{(s)})$ ; при расчете используются формулы (3), (4) и (6); следует учитывать, что для повторных посылок априорные вероятности будут совпадать с апостериорными для предыдущей посылки (см. формулу (6)).
- постройте график изменения апостериорного распределения вероятностей на примере любой 1-ой передаваемой буквы сообщения ( $n$  передач  $\Rightarrow n$  графиков друг под другом, на графике по оси  $X$  – номер символа, по оси  $Y$  – вероятность)
- по максимуму апостериорной вероятности определите наиболее вероятные буквы и составьте вариант исходного переданного сообщения для 1-й, 2-й и  $m$ -й посылок;
- проанализируйте, как повторные передачи сказались на принятии решения.

#### **1.2. Расчет энтропии и количества информации**

- Выберите в посылаемом сообщении произвольную букву (под номером  $s$ ), далее все вычисления будут относиться к этой букве;
- Определите апостериорные вероятности, рассматривая каждую передачу независимо от другой; схема вычислений следующая  $P(x_i) \rightarrow P(y_j / x_i) \rightarrow P(y_j) \rightarrow P(x_i / y_j)$ ; при расчете используйте формулы (3), (4) и (5).
- Определите условные энтропии  $H(X / y_j)$  на сообщения  $y_j$  по формуле (2), среднее количество информации  $I(X, y_j)$  об  $X$ , содержащееся в  $y_j$  по формуле (8).
- Определите среднюю условную энтропию  $H(X/Y)$  по формуле (7) и среднюю взаимную информацию  $I(X,Y)$  по формуле (9).
- Постройте графики изменения условной энтропии  $H(X / y_j)$  и количества информации  $I(X, y_j)$  от номера посылки.

**1.3. Сравните результаты п. 1.1 и 1.2 при различных заданиях изначальных априорных вероятностей.**

## Часть 2 Передача сообщения путем многократного дублирования

Рассмотрите  $m$  передач сообщений как передачу одного большого сообщения, в котором каждый символ многократно ( $m$ -кратно) дублируется

На входе  $X_{new} = [x_{new}^{(1)}; x_{new}^{(2)}; \dots; x_{new}^{(k)}] = [x^{(1)} x^{(1)} \dots x^{(1)}, x^{(2)} x^{(2)} \dots x^{(2)}, \dots, x^{(k)} x^{(k)} \dots x^{(k)}]$ ,

На выходе  $Y_{new} = [y_{new}^{(1)}; y_{new}^{(2)}; \dots; y_{new}^{(k)}] = [y_1^{(1)} y_2^{(1)} \dots y_m^{(1)}, y_1^{(2)} y_2^{(2)} \dots y_m^{(2)}, \dots, y_1^{(k)} y_2^{(k)} \dots y_m^{(k)}]$ .

При этом новый алфавит по сути –  $m$ -кратное дублирование старого алфавита:  
 $[x_{new1}; x_{new2}; \dots; x_{newn}] = [x_1 x_1 \dots x_1; x_2 x_2 \dots x_2; \dots; x_n x_n \dots x_n]$

### 2.1. Определение переданного сообщения

- вычислите априорное распределение вероятностей исходных букв алфавита  $p(x_i)$  – рассмотрите два случая (по аналогии с п.1. все дальнейшие расчеты в п. 2.1 и 2.2 необходимо выполнить для этих двух вариантов):
  - все символы равновероятны;
  - вероятности букв задаются исходя из известной информации о частоте букв в русском алфавите (таблица 2);
- вычислите апостериорное распределение вероятностей для каждой 1 буквы сообщения -  $P(x_{newi} / y_{new}^{(l)})$ ; при расчете используются формулы (3), (4);
- постройте график апостериорного распределения вероятностей на примере 1-ой передаваемой буквы сообщения
- по максимуму апостериорной вероятности определите наиболее вероятные буквы и составьте вариант исходного переданного сообщения – сравните его со случаем передачи сообщений последовательно

### 2.2. Расчет энтропии и количества информации

- Выберите в посылаемом сообщении ту же букву, что и использовалась в п. 1.2, далее все вычисления будут относиться к этой букве;
- Определите апостериорные вероятности; схема вычислений следующая  $P(x_{newi}) \rightarrow P(y_{new} / x_{newi}) \rightarrow P(y_{new}) \rightarrow P(x_{newi} / y_{new})$ ; при расчете используйте формулы (3), (4) и (5).
- Определите условную энтропию  $H(X_{new} / y_{new})$  на сообщения  $y_{new}$  по формуле (2), среднее количество информации  $I(X, y_{new})$  об  $X$ , содержащееся в  $y_{new}$  по формуле (8).
- Определите среднюю условную энтропию  $H(X_{new} / Y_{new})$  по формуле (7) и среднюю взаимную информацию  $I(X, Y_{new})$  по формуле (9).
- Сравните результаты (энтропия, количество информации) с п.1.2 и объясните их.

## Приложение 1 Теоретические основы

Пусть  $X$  - ансамбль возможных сообщений, которые могут быть переданы по каналам связи. Априорные вероятности, с которыми на передающей стороне может появиться  $i$ -ое сообщение, обозначим через  $p_i = p(x_i)$ .

В качестве характеристики априорной неопределенности генерации того или иного сообщения на передающей стороне Шеннон предложил применить следующий функционал энтропии:

$$H(X) = - \sum_{i=1}^n p(x_i) \log_2 p(x_i) \quad (1)$$

В этом функционале используется логарифм по основанию 2 в связи с тем, что в цифровых каналах связи информация обычно представляется в двоичных кодах, и энтропия измеряется в *битах*.

Энтропия является характеристикой неопределенности состояния ансамбля  $X$  в отличие от характеристики возможности наступления того или иного события, то есть вероятности. Энтропия не зависит от значений, которые может принимать тот или иной элемент ансамбля и от способа его представления. В частности, элементами ансамбля могут быть словесные описания или фотографические изображения. Энтропия характеризует степень хаотичности ансамбля и принимает максимальное значение, когда вероятности  $p(x_i)$  одинаковы.

Инструментарий теории информации, выдвинутой К.Шенноном, эффективно используется в теории и практике передачи информации и кодирования. В этих применениях ансамбль  $X$  - ансамбль возможных сообщений. Основные результаты теории информации относятся к передаче информации в двоичном коде и к каналам, ориентированным на передачу двоичных кодов. Передача такой информации осуществляется двоичными кодовыми словами, и при каждой такой передаче искажение отдельного символа в передаваемом слове заключается в том, что вместо 1 получатель принимает 0, или вместо нуля получатель принимает 1. При таких условиях канал передачи двоичной информации характеризуется вероятностью искажения символа. Схематическое представление простейшего канала связи, а именно, двоичного симметричного канала представлено на рис 5.

Симметричным этот канал называется потому, что вероятности искажения символов '0' и '1' одинаковы и равны  $q$ , как это показано на рисунке. Вероятность  $p$  - вероятность неискаженной передачи символа.




Рис.5. Двоичный симметричный канал




Рис.6. Передача сообщений по каналу с искажениями

Поскольку каждое сообщение  $x_i \in X$  передается кодовым словом, которое может состоять из нескольких символов '0' или '1', возможностей искажения слова при передаче по такому каналу гораздо больше (см. рис. 6, где принимаемые сообщения обозначены через  $y_1, y_2, \dots, y_j, \dots \in Y$ ). Вероятность искажения слова в общем случае отличается от вероятности искажения отдельного символа.

Понятно, что при передаче по каналам связи сообщения (слова)  $\mathbf{x}_i \in X$  и при получении сообщения  $\mathbf{y}_j \in Y$ , несмотря на искажения в каналах энтропия ансамбля  $X$ , несомненно, уменьшится и будет исчисляться условной энтропией на сообщение

$$H(X/Y_j) = -\sum_{i=1}^n p(x_i/Y_j) \cdot \log_2 p(x_i/Y_j). \quad (2)$$

Прим. Вероятности  $p(x_i/Y_j)$  называются апостериорными. Для их расчета необходимо использовать формулу Байеса

$$p(x_i/Y_j) = \frac{p(y_j/x_i)p(x_i)}{p(y_j)} = \frac{p(y_j/x_i)p(x_i)}{\sum_k p(y_j/x_k)p(x_k)} \quad (3)$$

$p(x_i)$  - априорные вероятности, вначале они могут быть выбраны произвольно и как правило они принимаются одинаковыми и равными  $1/N$ , где  $N$  – общее количество слов  $x_i$ .

$p(y_j/x_i)$  - условная вероятность приема  $y_j$  при условии, что было послано  $x_i$ . Данную вероятность легко найти следующим образом. Если общее количество разрядов в слове  $k$ , в  $t$  разрядах произошла ошибка (они проинвертировались), то вероятность очевидно равна

$$p(y_j/x_i) = p^{k-t} q^t \quad (4)$$

Здесь по-прежнему  $p$  – вероятность правильной передачи одного бита,  $q=1-p$  – вероятность ошибки.

$$p(y_j) = \sum_k p(y_j/x_k)p(x_k) \quad (5)$$

- вероятность приема  $y_j$  в данной задаче несет вспомогательный характер – она потребуется в том числе в дальнейших расчетах.

В случае, если при приеме одной и той же буквы несколько раз информация накапливается, для расчета апостериорных вероятностей последующих приемов в качестве априорных вероятностей необходимо использовать апостериорные вероятности после предыдущего принятого сообщения, т.е.:

$$p(x_i/Y_1Y_2...Y_{j-1}) = \frac{p(y_j/x_i)p(x_i/Y_1Y_2...Y_{j-1})}{p(y_j)} = \frac{p(y_j/x_i)p(x_i/Y_1Y_2...Y_{j-1})}{\sum_k p(y_j/x_k)p(x_k/Y_1Y_2...Y_{j-1})} \quad (6)$$

Для того, чтобы характеризовать всю систему приема - передачи, используют среднюю условную энтропию:

$$H(X/Y) = \sum_{j=1}^n p(y_j) \cdot H(X/Y_j) = H(X,Y) - H(Y) \quad (7)$$

$$\text{где } H(Y) = \sum_{j=1}^n p(y_j) \cdot \log_2 p(y_j), \quad H(X,Y) = -\sum_{j=1}^n \sum_{i=1}^n p(x_i, y_j) \cdot \log_2 p(x_i, y_j)$$

$H(X,Y)$  - совместная энтропия двух ансамблей, равная

$$H(X,Y) = H(X/Y) + H(Y) = H(Y/X) + H(X)$$

Количество информации об  $\mathbf{x}_i$ , полученное в одном сообщении  $\mathbf{y}_j$ :

$$I(x_i : y_j) = \log \frac{p(x_i, y_j)}{p(x_i)p(y_j)}.$$

Среднее количество информации об  $X$ , полученное в сообщении  $\mathbf{y}_j$

$$I(X : y_j) = -\sum_{i=1}^n p(x_i/Y_j) \log p(x_i) - H(X/Y_j) \quad (8)$$

Количество информации измеряется в тех же единицах, что и энтропия - в битах. Средняя взаимная информация, содержащаяся в  $Y$  об  $X$  или в  $X$  об  $Y$ :

$$I(X:Y) = \sum_{i=1}^n p(y_i) I(X:y_i) = H(X) - H(X/Y) \quad (9)$$

то есть это количество информации численно равно количеству неопределенности, устраненной при получении одного сообщения.

## Приложение 2 Вспомогательные материалы и таблицы

Используемый набор букв и символов:

'0123456789АБВГДЕЁЖЗИЙКЛМНОПРСТУФХЦЧШЩЬЪЭЮЯабвгдеёжзийклмнопрстуфхцчшщъьэ  
юя.,!:-\_№()'

Каждая буква кодируется своим номером в наборе, представленным в двоичном коде (см. табл.). При передаче без ошибки буквы с кодом  $x_7x_6x_5x_4x_3x_2x_1x_0$  на принимающей стороне будет получен такой же код  $x_7x_6x_5x_4x_3x_2x_1x_0$ .

Табл. 1 Символы и их коды

Символ	Код	Символ	Код	Символ	Код	Символ	Код	Символ	Код
0	0000000	Й	0010100	Э	0101000	р	0111100	?	1010000
1	0000001	К	0010101	Ю	0101001	с	0111101	-	1010001
2	0000010	Л	0010110	Я	0101010	т	0111110	_	1010010
3	0000011	М	0010111	а	0101011	у	0111111	№	1010011
4	0000100	Н	0011000	б	0101100	ф	1000000	(	1010100
5	0000101	О	0011001	в	0101101	х	1000001	)	1010101
6	0000110	П	0011010	г	0101110	ц	1000010	Пробел	1010110
7	0000111	Р	0011011	д	0101111	ч	1000011		
8	0001000	С	0011100	е	0110000	ш	1000100		
9	0001001	Т	0011101	ё	0110001	щ	1000101		
А	0001010	У	0011110	ж	0110010	ь	1000110		
Б	0001011	Ф	0011111	з	0110011	ы	1000111		
В	0001100	Х	0100000	и	0110100	ъ	1001000		
Г	0001101	Ц	0100001	й	0110101	э	1001001		
Д	0001110	Ч	0100010	к	0110110	ю	1001010		
Е	0001111	Ш	0100011	л	0110111	я	1001011		
Ё	0010000	Щ	0100100	м	0111000	.	1001100		
Ж	0010001	Ъ	0100101	н	0111001	,	1001101		
З	0010010	Ы	0100110	о	0111010	!	1001110		
И	0010011	Ь	0100111	п	0111011	:	1001111		

Табл. 2 Частота букв в русском языке

Буква	Частота	Буква	Частота	Буква	Частота
а	8.66	л	4.32	ц	0.52
б	1.51	м	3.29	ч	1.27
в	4.19	н	6.35	ш	0.77
г	1.41	о	9.28	щ	0.49
д	2.56	п	3.35	ъ	0.04
е	8.10	р	5.53	ы	2.11
ж	0.78	с	5.45	ь	1.90
з	1.81	т	6.30	э	0.17
и	7.45	у	2.90	ю	1.03
й	1.31	ф	0.40	я	2.22
к	3.47	х	0.92		